Abgabe Codebase

April 7, 2020

Ersteller: 2005981 Wahlfach, 1641654 Wahlfach

Dozent/-in: Prof. Dr. Monika Kochanowski

[1]:
```
#Imports

#Allgemein
import pandas as pd
import seaborn  as sb
import sklearn
import math

#Regressoren
from sklearn.ensemble import RandomForestRegressor
from sklearn.ensemble import GradientBoostingRegressor
from sklearn.linear_model import LinearRegression
from sklearn.model_selection import cross_val_score

#Classifier
from sklearn import tree
from sklearn.ensemble import RandomForestClassifier
from sklearn.ensemble import GradientBoostingClassifier

# Bewertungsmetriken
from sklearn.metrics import accuracy_score, mean_squared_error, r2_score,␣
 ↪confusion_matrix

#Text to numbers
import nltk
import numpy as np

#Modelle speichern und laden
from joblib import dump, load

#Visulalisierung Decision Tree
import matplotlib.pyplot as plt
```

1 Methoden zum Anwenden von Modellen und Bewerten

[2]:
```
def doEverythingRegression(filename):
    regressionModel, classificationModel = importModels("trainedModels.joblib")
    classificationData = readData(filename)
    return applyRegressor(regressionModel, classificationData)

def doEverythingClassification(filename):
    regressionModel, classificationModel = importModels("trainedModels.joblib")
    regressionData = readData(filename)
    return applyClassifier(classificationModel, regressionData)


def readData(filename):
    if str(filename):
        dataFrame = pd.read_csv(filename, sep= ";")
        return dataFrame;

def prepareDataRegression(dataFrame):
    if type(dataFrame) == pd.core.frame.DataFrame:
        #Data Preparation
        #Spalten entfernen
        if "YrSold" in dataFrame.columns:
            dataFrame = dataFrame.drop("YrSold", axis=1)
        #Dies wird entfernt wei lman oben herruasgefunden hat das es mit nichts␣
 ↪correliert
        # es also keine auswirkung auf irgendwas hat. und es auch nur 4␣
 ↪verschiedene Werte sind.
        if "TotRmsAbvGrd" in dataFrame.columns:
            dataFrame = dataFrame.drop("TotRmsAbvGrd", axis=1)
        #Dies wird entfernt,
        #weil es eine sehr starke mit LIvArea zu sammenhängt man also die␣
 ↪gleiche Information in zwei Features hat.


        #One hot encoding
        stringLabels =␣
 ↪["MSZoning","Neighborhood","BldgType","RoofStyle","HeatingQC","CentralAir"]
        for element in stringLabels:
            dataFrame.loc[:,element] = text_to_numbers(dataFrame.loc[:,element])

        return dataFrame

def splitDataRegression(dataFrame):
    if type(dataFrame) == pd.core.frame.DataFrame:
        #Data Splitting in Data und Sale Price
        x = dataFrame.drop('SalePrice', axis=1)
```

```
        y = dataFrame.SalePrice
        return x,y

def applyRegressor(model, dataFrame):
    if type(dataFrame) == pd.core.frame.DataFrame:
        dataFrame = prepareDataRegression(dataFrame)
        x,y = splitDataRegression(dataFrame)
        try:
            if isinstance(model, sklearn.linear_model.base.LinearRegression) :
            #nutzen von nur 3 Features bei der Linearen Regression.
                x = x.iloc[:, [4 ,9, 12]]
        except AttributeError:
            if isinstance(model, sklearn.linear_model._base.LinearRegression) :
            #nutzen von nur 3 Features bei der Linearen Regression.
                x = x.iloc[:, [4 ,9, 12]]
        #dieser try except block weil manche versionen _base verlangen und␣
 ↪andere base




        #Führe Prediction durch und berechne Messwerte
        pred = model.predict(x)
        r2 = r2_score(y,pred)
        mse = mean_squared_error(y, pred)
        rmse = np.sqrt(mse)
        mape = np.mean(np.abs((y - pred) / y)) * 100
        maxDiff = np.amax(np.subtract(y,pred))

        return {"r2":r2,"mse": mse,"rmse":rmse,"mape":mape,"maxDiff": maxDiff}

def splitDataClassification(dataFrame):
    if type(dataFrame) == pd.core.frame.DataFrame:
        x = dataFrame.drop("CentralAir",axis = 1)
        y = dataFrame["CentralAir"]
        return x,y

def applyClassifier(model, dataFrame):
    if type(dataFrame) == pd.core.frame.DataFrame:
        dataFrame = prepareDataRegression(dataFrame)
        x, y = splitDataClassification(dataFrame)
        #Führe Prediction durch und berechne Messwerte
        prediction = model.predict(x)
        dataFrameSize = len(x.index)
        confMat = confusion_matrix(y,prediction).flatten()
        #diesen Abschnitt bitte erst testen
        if len(confMat) < 4:
```

```
            zeros = (4-len(confMat))*[0]
            confMat =np.append(confMat,zeros)
        truePositive,falseNegative,falsePositive,trueNegative = np.
↪array(confMat,dtype='f')


        if (trueNegative + falsePositive) > 0:
            falsePositiveRate = falsePositive/(trueNegative + falsePositive)
        else:
            falsePositiveRate = 0
        if (truePositive + falseNegative) > 0:
            falseNegativeRate = falseNegative/(truePositive + falseNegative)
        else:
            falseNegativeRate = 0

        accuracy = (trueNegative + truePositive) / len(dataFrame)

        return {"accuracy": accuracy, "falsePositiveRate": falsePositiveRate,␣
↪"falseNegativeRate": falseNegativeRate}


def text_to_numbers(text, cutoff_for_rare_words = 1):
    """Function to convert text to numbers. Text must be tokenzied so that
    test is presented as a list of words. The index number for a word
    is based on its frequency (words occuring more often have a lower index).
    This is a Methode from Stackoverflow, that is created for Text but it is␣
↪highly
    change to the spefific problem. So do not wonder is a different coding style
    """

    # Flatten list if sublists are present
    if len(text) > 1:
        flat_text = [sublist for sublist in text]

    else:
        flat_text = text

    # get word freuqncy
    fdist = nltk.FreqDist(flat_text)

    # Convert to Pandas dataframe
    df_fdist = pd.DataFrame.from_dict(fdist, orient='index')
    df_fdist.columns = ['Frequency']

    # Sort by word frequency
    df_fdist.sort_values(by=['Frequency'], ascending=False, inplace=True)
```

```
    # Add word index
    number_of_words = df_fdist.shape[0]
    df_fdist['word_index'] = list(np.arange(number_of_words)+1)



    # Convert pandas to dictionary
    word_dict = df_fdist['word_index'].to_dict()


    # Use dictionary to convert words in text to numbers
    text_numbers = []
    for string in text:
        string_numbers = word_dict[string]
        text_numbers.append(string_numbers)

    return (text_numbers)


def exportModels(filename, regressionModel, classificationModel):
    dump([regressionModel, classificationModel], filename)

def importModels(filename):
    return load(filename)
```

[3]:
```
doEverythingRegression("SetFiltered.csv")
```

[3]:
```
{'r2': 0.9730793130103527,
 'mse': 137136032.5170478,
 'rmse': 11710.509490071207,
 'mape': 4.601123987241046,
 'maxDiff': 86444.59270000004}
```

[4]:
```
doEverythingClassification("SetFiltered.csv")
```

[4]:
```
{'accuracy': 0.9877777777777778,
 'falsePositiveRate': 0.10909091,
 'falseNegativeRate': 0.00591716}
```

2 Begin Aufgabe 1 - Erste Erkenntnisse first look und Data Preparation

[5]:
```
data = pd.read_csv("SetFiltered.csv", sep= ";")
type(data)
```

[5]:
```
pandas.core.frame.DataFrame
```

[6]:
```
data
```

[6]:

	MSZoning	LotArea	Neighborhood	BldgType	OverallQual	OverallCond	\
0	RL	9590	Timber	1Fam	7	5	
1	RL	12256	NoRidge	1Fam	8	5	
2	RL	12108	Edwards	Duplex	4	4	
3	RL	7500	Sawyer	1Fam	5	5	
4	RM	6000	OldTown	2fmCon	4	4	
..	…	…	…	…	…	…	
895	RL	8750	CollgCr	1Fam	7	5	
896	RL	8064	NAmes	1Fam	5	7	
897	RL	13005	NWAmes	1Fam	7	7	
898	RL	9375	CollgCr	1Fam	8	5	
899	RL	9135	CollgCr	1Fam	7	5	

	YearBuilt	YearRemodAdd	RoofStyle	TotalBsmtSF	HeatingQC	CentralAir	\
0	2003	2003	Gable	868	Ex	Y	
1	1994	1995	Gable	1463	Ex	Y	
2	1955	1955	Gable	1440	TA	N	
3	1963	1963	Gable	1040	Fa	Y	
4	1953	1953	Gable	936	TA	N	
..	…	…	…	…	…	…	
895	1996	1996	Gable	880	Ex	Y	
896	1949	2006	Gable	672	Ex	Y	
897	1980	1980	Gable	845	TA	Y	
898	2002	2002	Gable	1284	Ex	Y	
899	2002	2003	Gable	1536	Ex	Y	

	GrLivArea	TotRmsAbvGrd	GarageCars	YrSold	SalePrice
0	1146	6	2	2007	187500
1	2622	9	2	2010	325000
2	1440	8	0	2008	118000
3	1040	5	1	2010	133000
4	936	4	2	2009	93000
..	…	…	…	…	…
895	1716	7	2	2009	191000
896	924	6	2	2007	122900
897	2353	10	2	2009	260000
898	2169	7	2	2007	228500
899	1536	7	2	2008	214000

[900 rows x 17 columns]

Null gibt es sonst nicht NAN auch nicht -1 auch nicht

[7]:
```
data[81:82]
```

[7]:
```
    MSZoning  LotArea Neighborhood BldgType  OverallQual  OverallCond  \
81  C (all)     8500       IDOTRR     1Fam            4            4

    YearBuilt  YearRemodAdd RoofStyle  TotalBsmtSF HeatingQC CentralAir  \
81       1920          1950   Gambrel          649        TA          N

    GrLivArea  TotRmsAbvGrd  GarageCars  YrSold  SalePrice
81       1317             6           1    2008      40000
```

Diese Zeilen ist weil wenn man die csv mit Libre Office öffnet war (all) in einer anderen Spalte wodurch das ganze Datenset verschoben war. Dies ist nur um sicher zustellen, dass es nicht mehr so ist.

[8]:
```
data.describe()
```

[8]:
```
             LotArea  OverallQual  OverallCond    YearBuilt  YearRemodAdd  \
count     900.000000   900.000000   900.000000   900.000000    900.000000
mean    10629.817778     6.014444     5.652222  1969.347778   1984.185556
std      9947.088936     1.336912     1.151555    29.573049     20.195265
min      1300.000000     1.000000     1.000000  1872.000000   1950.000000
25%      7432.250000     5.000000     5.000000  1953.000000   1966.000000
50%      9475.000000     6.000000     5.000000  1971.000000   1993.000000
75%     11700.000000     7.000000     6.000000  1998.000000   2002.000000
max    164660.000000    10.000000     9.000000  2009.000000   2009.000000

       TotalBsmtSF    GrLivArea  TotRmsAbvGrd  GarageCars       YrSold  \
count   900.000000   900.000000    900.000000  900.000000   900.000000
mean   1028.166667  1487.441111      6.415556    1.745556  2007.896667
std     403.019702   504.588271      1.601786    0.715887     1.306010
min       0.000000   334.000000      2.000000    0.000000  2006.000000
25%     790.250000  1102.750000      5.000000    1.000000  2007.000000
50%     968.500000  1443.500000      6.000000    2.000000  2008.000000
75%    1249.500000  1750.500000      7.000000    2.000000  2009.000000
max    3206.000000  4316.000000     12.000000    4.000000  2010.000000

           SalePrice
count     900.000000
mean   176184.454444
std     71412.482393
min     39300.000000
25%    130000.000000
50%    161000.000000
75%    205000.000000
max    755000.000000
```

Lot Area riesiges Maximum kann riesige Auswirkungen haben. Riesiges Minimum und Maximum

[9]:
```
data[data["LotArea"].idxmax():data["LotArea"].idxmax()+1]
```

[9]:
```
     MSZoning  LotArea Neighborhood BldgType  OverallQual  OverallCond  \
844        RL   164660       Timber   2fmCon            5            6

     YearBuilt  YearRemodAdd RoofStyle  TotalBsmtSF HeatingQC CentralAir  \
844       1965          1965     Gable         1499        Ex          Y

     GrLivArea  TotRmsAbvGrd  GarageCars  YrSold  SalePrice
844       1786             7           2    2008     228950
```

[10]:
```
data["MSZoning"].unique()
```

[10]:
```
array(['RL', 'RM', 'FV', 'RH', 'C (all)'], dtype=object)
```

[11]:
```
data['MSZoning'].value_counts()
```

[11]:
```
RL         716
RM         145
FV          28
RH          10
C (all)      1
Name: MSZoning, dtype: int64
```

C (all) ist nur alleine

[12]:
```
data = data.query("MSZoning != 'C (all)'")
```

Da es nur ein C(all) gibt steckt in C(all) keine Information und es wird gesaubert in Sinne der Daten aufbereitung

[13]:
```
data['Neighborhood'].value_counts()
```

[13]:
```
NAmes      150
CollgCr    103
OldTown     71
Edwards     53
Sawyer      52
Gilbert     47
NWAmes      46
BrkSide     41
NridgHt     39
SawyerW     37
Crawfor     34
Somerst     34
Mitchel     33
NoRidge     26
Timber      21
IDOTRR      20
SWISU       18
```

```
ClearCr     17
StoneBr     13
MeadowV     12
BrDale       9
Blmngtn      9
Veenker      8
NPkVill      5
Blueste      1
Name: Neighborhood, dtype: int64
```

Blueste kommt nur einmal vor

[14]:
```
data = data.query("Neighborhood != 'Blueste'")
```

Der Grund warum dies gemacht wird ist, man kann mit der Information Blueste ncihts anfangen wenn es nur einen Eintrag gibt nichts anfangen

[15]:
```
data['BldgType'].value_counts()
```

[15]:
```
1Fam      758
TwnhsE     67
Duplex     29
Twnhs      27
2fmCon     17
Name: BldgType, dtype: int64
```

Einfamiliehaushalt ist am häufigsten

[16]:
```
data['OverallQual'].value_counts()
```

[16]:
```
5     248
6     243
7     193
8      92
4      77
9      23
3      13
10      6
1       2
2       1
Name: OverallQual, dtype: int64
```

[17]:
```
sb.lineplot(data['OverallQual'].value_counts().keys(), data['OverallQual'].
↪value_counts())
```

[17]:
```
<matplotlib.axes._subplots.AxesSubplot at 0x17a91cd4208>
```

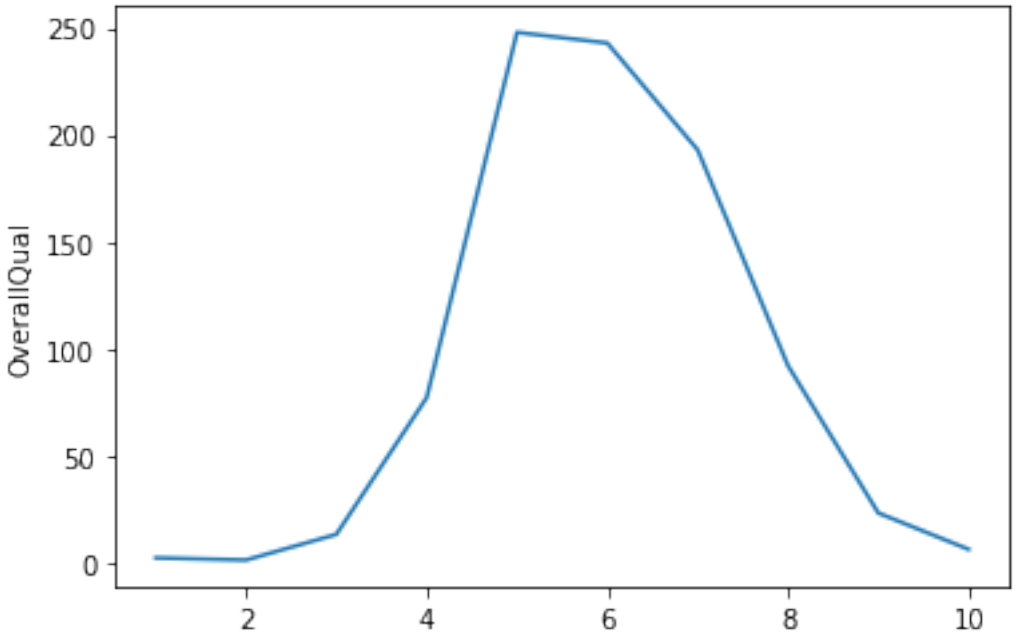

schaut nach einer Gaussverteilung aus

[18]:
```
data['OverallCond'].value_counts()
```

[18]:
```
5    481
6    157
7    134
8     55
4     40
9     17
3     12
2      1
1      1
Name: OverallCond, dtype: int64
```

[19]:
```
sb.lineplot(data['OverallCond'].value_counts().keys(), data['OverallCond'].
↪value_counts())
```

[19]:
```
<matplotlib.axes._subplots.AxesSubplot at 0x17ad356c248>
```

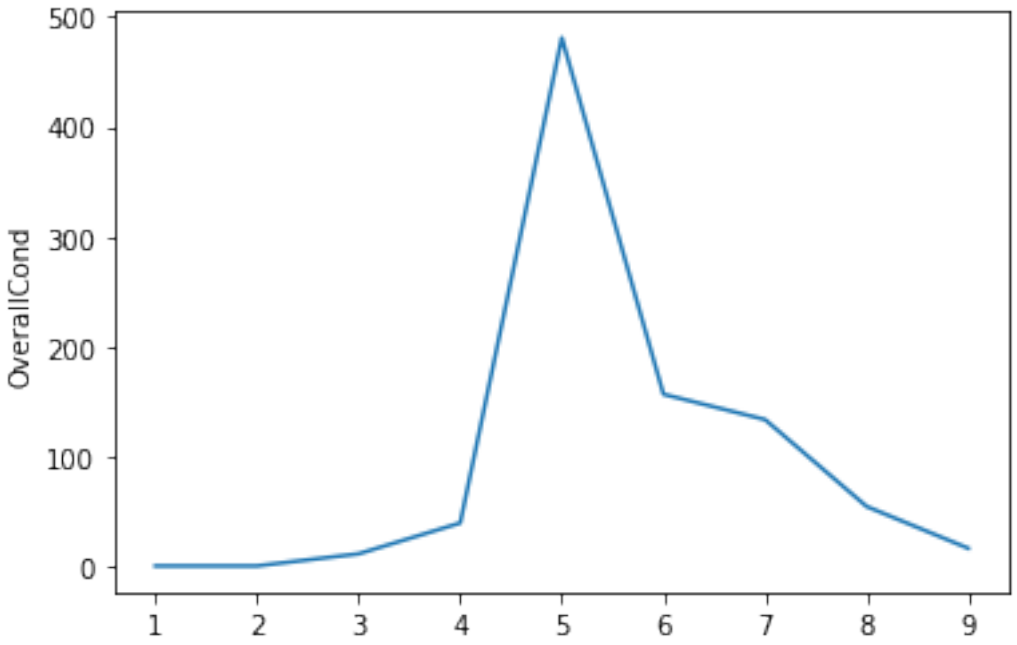

[20]:
```
data['RoofStyle'].value_counts()
```

[20]:
```
Gable      707
Hip        171
Flat         7
Gambrel      6
Mansard      5
Shed         2
Name: RoofStyle, dtype: int64
```

Giebel und hip Dächer sind auf häufigsten

[21]:
```
data['HeatingQC'].value_counts()
```

[21]:
```
Ex    448
TA    262
Gd    161
Fa     26
Po      1
Name: HeatingQC, dtype: int64
```

schlechte warmequaltität der Heizung ist nur ein Haus

[22]:
```
data['CentralAir'].value_counts()
```

[22]:
```
Y    844
N     54
Name: CentralAir, dtype: int64
```

Meiste haben eine Klimaanlage. 0,93% wichtig um Klassifiakation später zu beurteilen.

[23]:
```
sb.lineplot(data['GrLivArea'].value_counts().keys(), data['GrLivArea'].
↪value_counts())
```

[23]:
```
<matplotlib.axes._subplots.AxesSubplot at 0x17a91ceaf88>
```

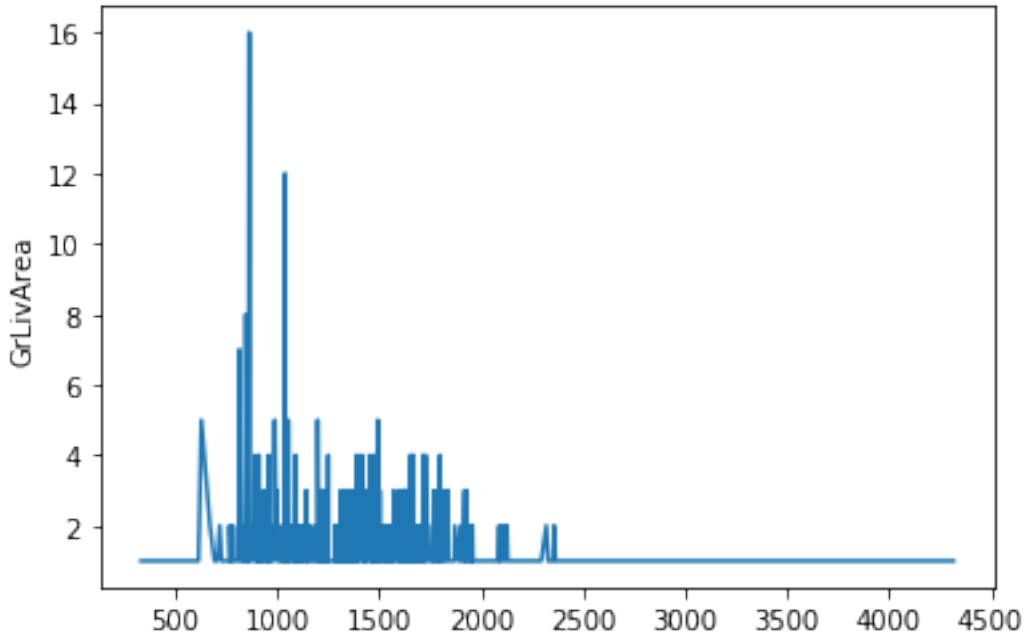

Viele kleine und der eine ausreisser

[24]:
```
sb.lineplot(data['TotRmsAbvGrd'].value_counts().keys(), data['TotRmsAbvGrd'].
↪value_counts())
```

[24]:
```
<matplotlib.axes._subplots.AxesSubplot at 0x17ad668f088>
```

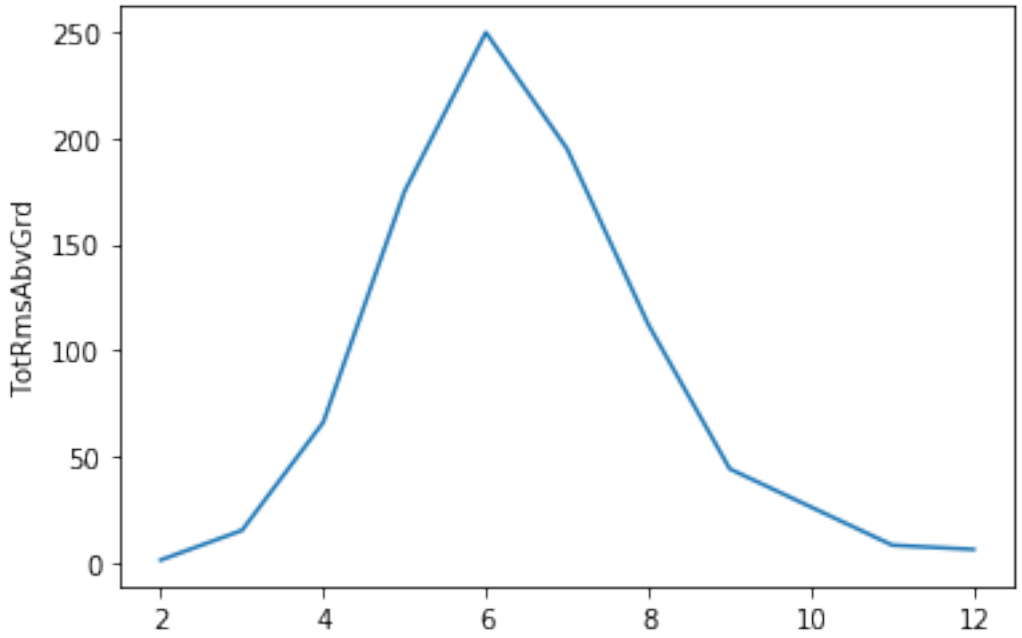

[25]:
```
sb.lineplot(data['GarageCars'].value_counts().keys(), data['GarageCars'].
↪value_counts())
```

[25]: <matplotlib.axes._subplots.AxesSubplot at 0x17ad76d4d08>

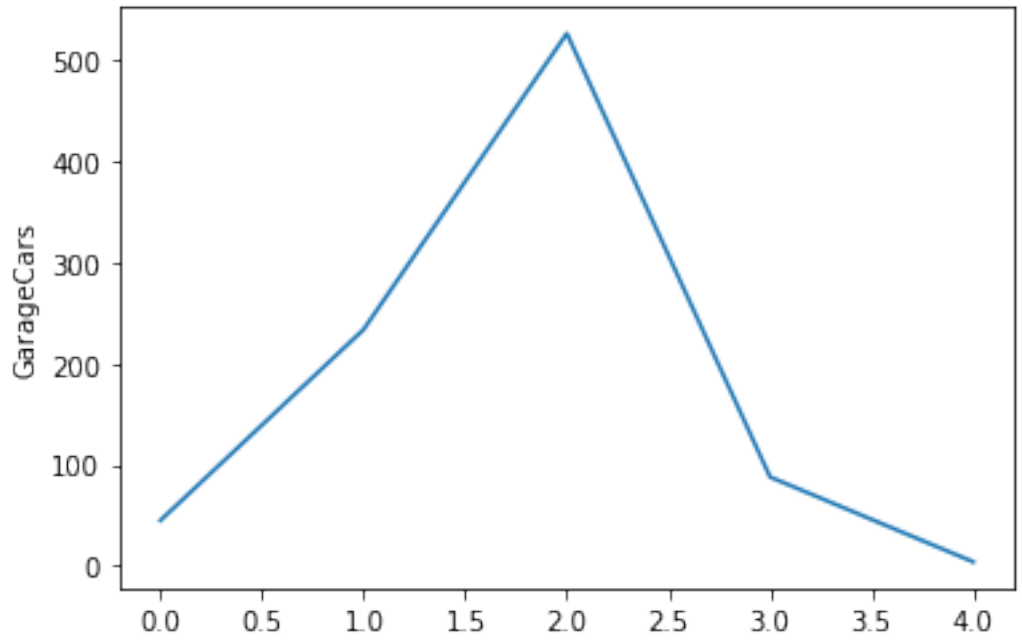

[26]:
```
sb.lineplot(data['YrSold'].value_counts().keys(), data['YrSold'].value_counts())
```

[26]:
```
<matplotlib.axes._subplots.AxesSubplot at 0x17ad9762a48>
```

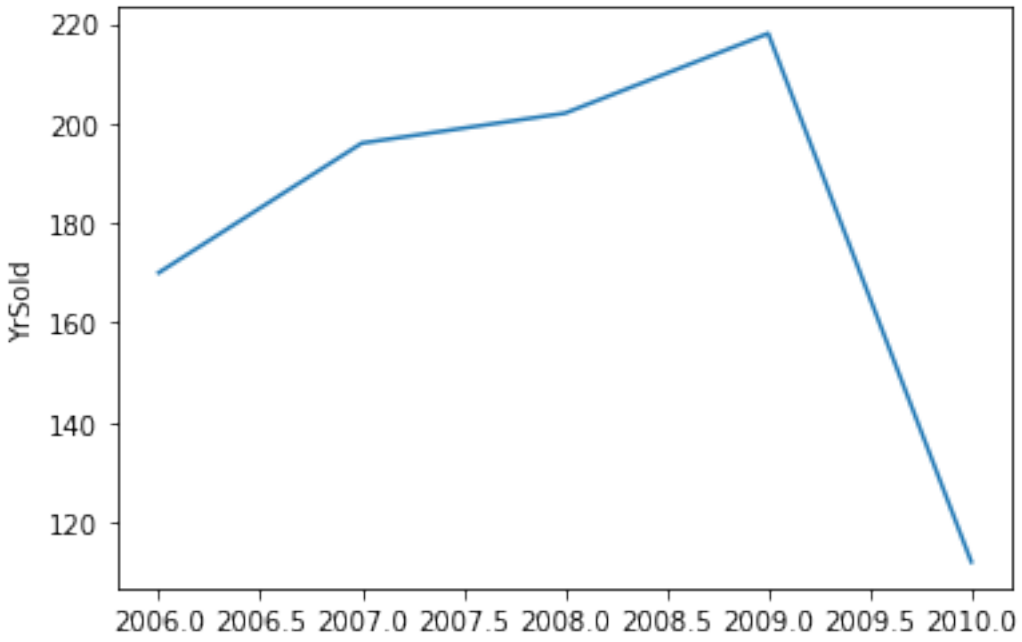

Was war 2009.5? - Warscheinlich langsames Ende der Datenerhebung

[27]:
```
data['YrSold'].value_counts()
```

[27]:
```
2009    218
2008    202
2007    196
2006    170
2010    112
Name: YrSold, dtype: int64
```

Dieser Datensatz enthält nur 4 Jahre in Year Sold

[28]:
```
sb.lineplot(data['YearBuilt'].value_counts().keys(), data['YearBuilt'].
↪value_counts())
```

[28]:
```
<matplotlib.axes._subplots.AxesSubplot at 0x17a97ea2308>
```

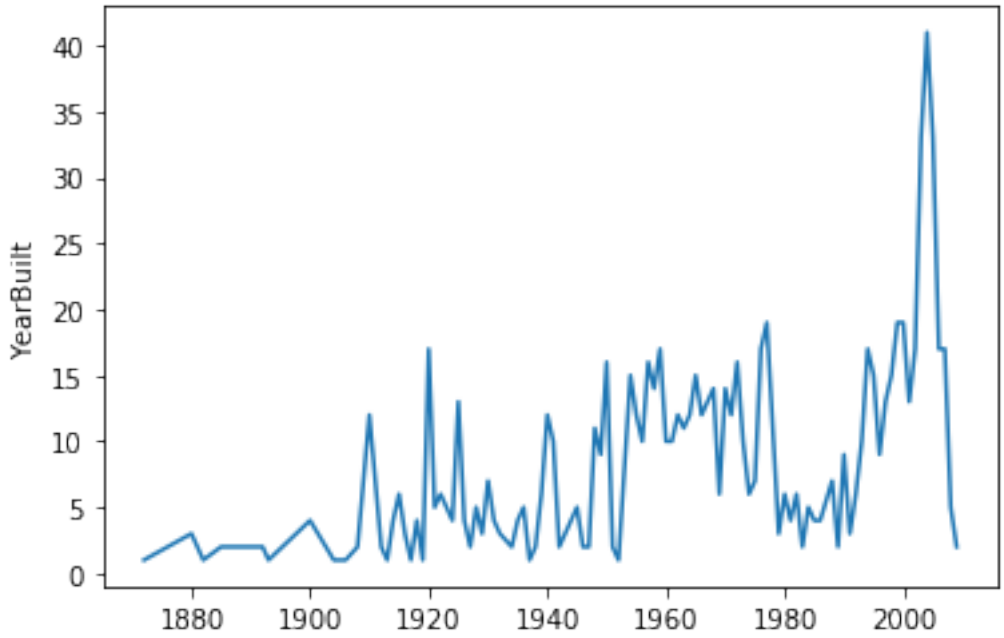

[29]:
```
data['YearRemodAdd'].value_counts()
```

[29]:
```
1950    111
2005     53
2004     46
2006     38
2000     37
2002     36
2003     35
2007     32
1996     26
1995     25
1997     23
1998     23
1999     20
1994     16
2001     15
1976     15
2008     14
1972     14
1993     13
1970     13
1977     13
1966     12
1959     12
1990     12
```

```
1978     11
1965     11
1968     11
1967     11
1973     10
1971     10
1964      9
1962      9
1991      9
1963      8
1980      8
1975      8
1985      8
1988      8
1957      7
1960      7
1992      7
1954      7
1956      7
1987      7
1981      7
1955      7
1958      7
1969      6
1989      6
1982      6
1953      6
2009      4
1961      4
1979      4
1983      3
1984      3
1986      3
1974      2
1951      2
1952      1
Name: YearRemodAdd, dtype: int64
```

[30]:
```
sb.lineplot(data['YearRemodAdd'].value_counts().keys(), data['YearRemodAdd'].
↪value_counts())
```

[30]:
```
<matplotlib.axes._subplots.AxesSubplot at 0x17ae3b81048>
```

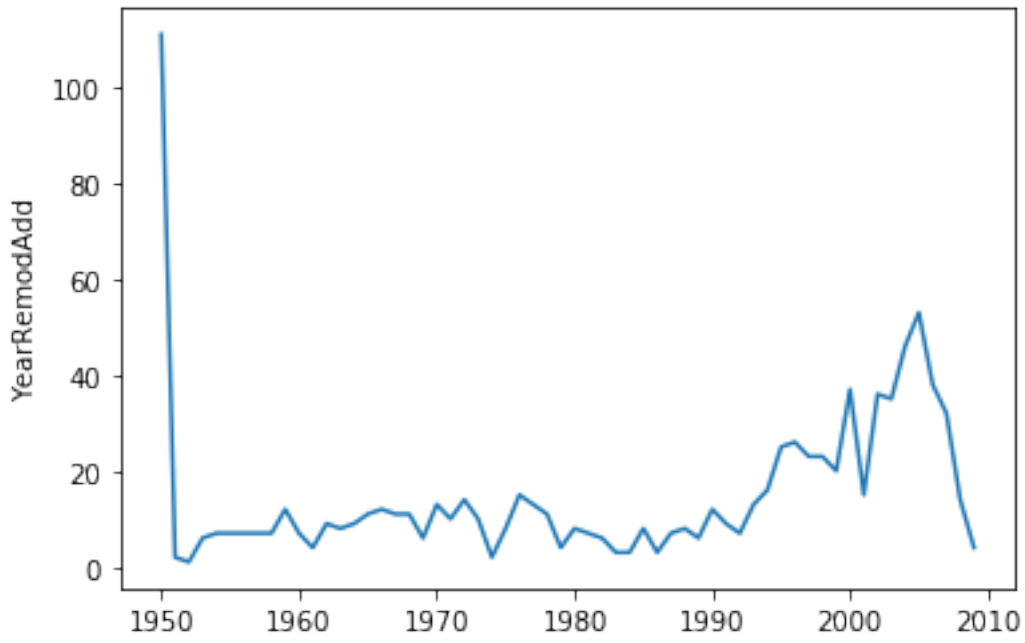

1950 gab es eine große renoirierungswelle der in dem Zeitraum (con Year Sold siehe oben) verkauften Häuser

[31]:
```
data.corr()
```

[31]:

	LotArea	OverallQual	OverallCond	YearBuilt	YearRemodAdd
LotArea	1.000000	0.078118	0.008611	-0.002769	0.013309
OverallQual	0.078118	1.000000	-0.070117	0.505580	0.497455
OverallCond	0.008611	-0.070117	1.000000	-0.413357	0.106004
YearBuilt	-0.002769	0.505580	-0.413357	1.000000	0.531105
YearRemodAdd	0.013309	0.497455	0.106004	0.531105	1.000000
TotalBsmtSF	0.214496	0.503372	-0.179958	0.375120	0.249978
GrLivArea	0.241608	0.579505	-0.064906	0.150368	0.234302
TotRmsAbvGrd	0.170915	0.420298	-0.042361	0.058768	0.143257
GarageCars	0.175377	0.570377	-0.175688	0.502403	0.384041
YrSold	-0.028536	0.015041	-0.013004	0.042530	0.066916
SalePrice	0.294612	0.778689	-0.048636	0.471721	0.463600

	TotalBsmtSF	GrLivArea	TotRmsAbvGrd	GarageCars	YrSold
LotArea	0.214496	0.241608	0.170915	0.175377	-0.028536
OverallQual	0.503372	0.579505	0.420298	0.570377	0.015041
OverallCond	-0.179958	-0.064906	-0.042361	-0.175688	-0.013004
YearBuilt	0.375120	0.150368	0.058768	0.502403	0.042530
YearRemodAdd	0.249978	0.234302	0.143257	0.384041	0.066916
TotalBsmtSF	1.000000	0.391654	0.255091	0.408928	0.049185
GrLivArea	0.391654	1.000000	0.835124	0.476622	-0.013700

```
TotRmsAbvGrd     0.255091   0.835124      1.000000    0.357591 -0.016895
GarageCars       0.408928   0.476622      0.357591    1.000000  0.009687
YrSold           0.049185  -0.013700     -0.016895    0.009687  1.000000
SalePrice        0.628727   0.758611      0.550466    0.633621  0.010421
```

```
              SalePrice
LotArea        0.294612
OverallQual    0.778689
OverallCond   -0.048636
YearBuilt      0.471721
YearRemodAdd   0.463600
TotalBsmtSF    0.628727
GrLivArea      0.758611
TotRmsAbvGrd   0.550466
GarageCars     0.633621
YrSold         0.010421
SalePrice      1.000000
```

Starke corr zwischen Preis und Qualität, TotalMsmtSF, LivArea, sowie große Garage. Außerdem livArea und room above ground, Idee: eines weglassen

[32]:
```
dataP = data.drop(columns = ["TotRmsAbvGrd"])
```

[33]:
```
dataP = dataP.drop(columns = ["YrSold"])
```

Hat corr kaum relation mit SalePrice und auch mit den anderen keine, dassheißt hier gibt es keinen Mehrwert

Weil Daten doppelt mit livArea

[34]:
```
sb.scatterplot(dataP["OverallQual"],dataP["SalePrice"])
```

[34]:
```
<matplotlib.axes._subplots.AxesSubplot at 0x17aff957f48>
```

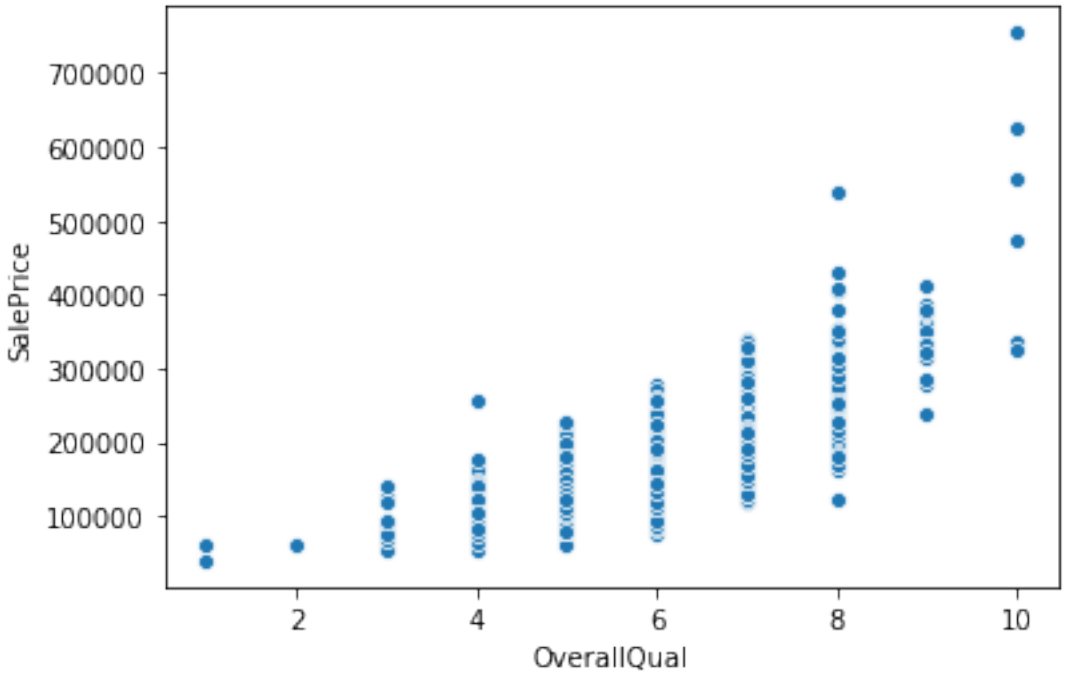

Qualitat hat vorher definierten range

[35]:
```
sb.boxplot(dataP["LotArea"])
```

[35]:
```
<matplotlib.axes._subplots.AxesSubplot at 0x17ad661ee08>
```

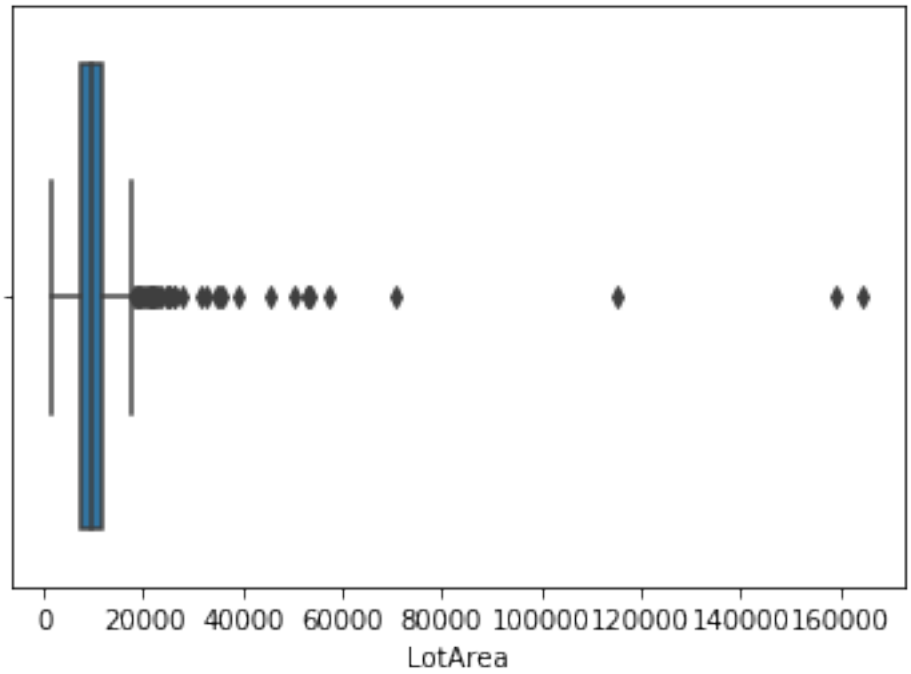

Ausreißer nach oben haben großen Abstand

[36]:
```
dataP = dataP.sample(frac=1, random_state = 42)
#Die Daten zufällig anordnen, random state damit Beispielrechnung richtig und
 ↪Ergebnisse gleich bleiben
```

[37]:
```
labels = dataP["SalePrice"]
labels
```

[37]:
```
332    117000
639    360000
327    130500
850    185850
39     337500
        …
107     80000
271    179500
862    188700
436    213000
103     60000
Name: SalePrice, Length: 898, dtype: int64
```

[38]:
```
sb.boxplot(dataP["SalePrice"])
```

[38]:
```
<matplotlib.axes._subplots.AxesSubplot at 0x17ae5d01808>
```

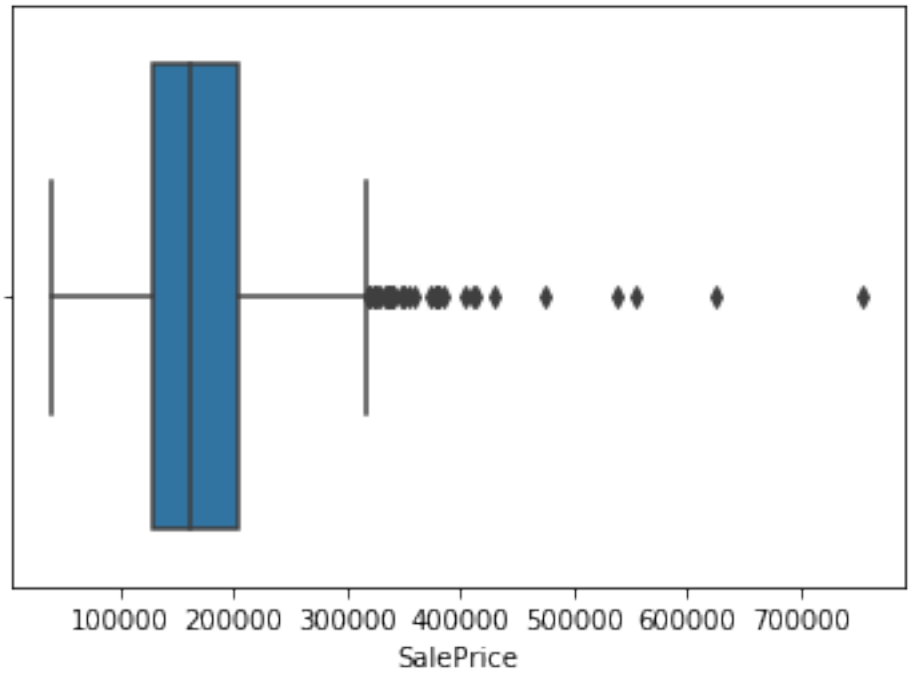

[39]:
```
sb.scatterplot(dataP["GrLivArea"],dataP["SalePrice"])
```

[39]:
```
<matplotlib.axes._subplots.AxesSubplot at 0x17affab9ac8>
```

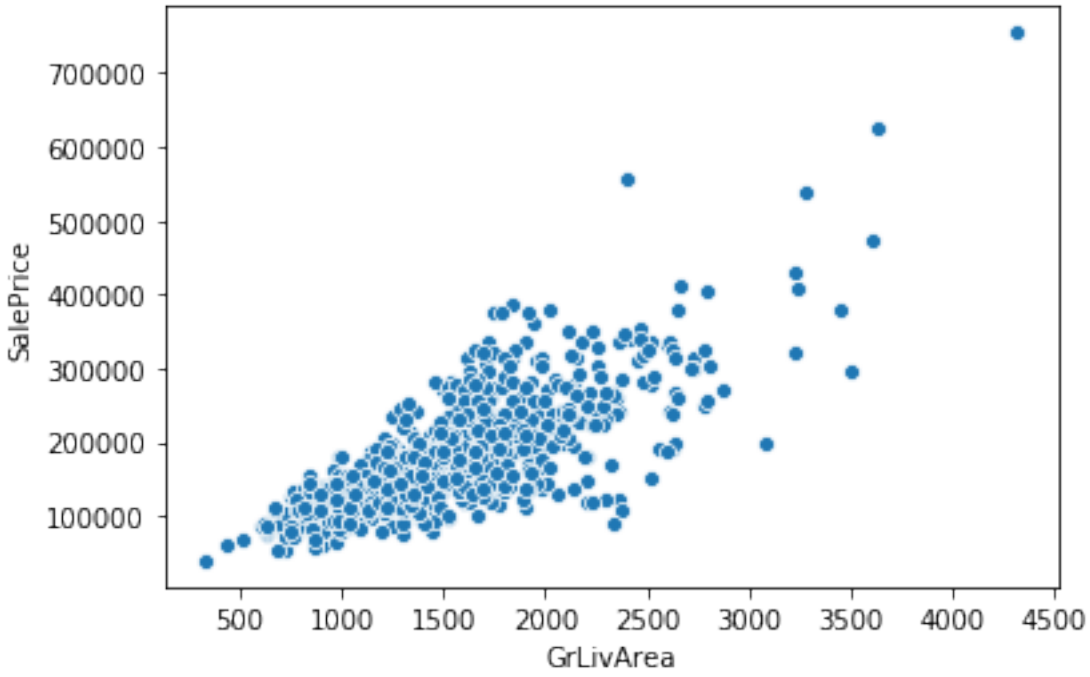

Am Graph lässt sich erkennen, dass Ausreißer von Größe und Preis zusammenhängen und deswegen müssen Ausreißer nicht rausgenommen werden.

[40]:
```
lenDataSet = len(dataP)
```

Durchführung des Encodings von Strings in Zahlen. Es wurde sich bewusst nicht für One Hot Encoding entscheiden um die Anzahl an Features einzusparen.

[41]:
```
dataP.loc[:,"MSZoning"]
```

[41]:
```
332    RL
639    RL
327    RL
850    RL
39     RL
       ..
107    RM
271    RL
862    RL
```

```
436    RL
103    RL
Name: MSZoning, Length: 898, dtype: object
```

[42]:
```
stringLabels =␣
↪["MSZoning","Neighborhood","BldgType","RoofStyle","HeatingQC","CentralAir"]
```

[43]:
```
for element in stringLabels:
    dataP.loc[:,element] = text_to_numbers(dataP.loc[:,element])
data
```

[43]:

	MSZoning	LotArea	Neighborhood	BldgType	OverallQual	OverallCond	\
0	RL	9590	Timber	1Fam	7	5	
1	RL	12256	NoRidge	1Fam	8	5	
2	RL	12108	Edwards	Duplex	4	4	
3	RL	7500	Sawyer	1Fam	5	5	
4	RM	6000	OldTown	2fmCon	4	4	
..	…	…	…	…	…	…	
895	RL	8750	CollgCr	1Fam	7	5	
896	RL	8064	NAmes	1Fam	5	7	
897	RL	13005	NWAmes	1Fam	7	7	
898	RL	9375	CollgCr	1Fam	8	5	
899	RL	9135	CollgCr	1Fam	7	5	

	YearBuilt	YearRemodAdd	RoofStyle	TotalBsmtSF	HeatingQC	CentralAir	\
0	2003	2003	Gable	868	Ex	Y	
1	1994	1995	Gable	1463	Ex	Y	
2	1955	1955	Gable	1440	TA	N	
3	1963	1963	Gable	1040	Fa	Y	
4	1953	1953	Gable	936	TA	N	
..	…	…	…	…	…	…	
895	1996	1996	Gable	880	Ex	Y	
896	1949	2006	Gable	672	Ex	Y	
897	1980	1980	Gable	845	TA	Y	
898	2002	2002	Gable	1284	Ex	Y	
899	2002	2003	Gable	1536	Ex	Y	

	GrLivArea	TotRmsAbvGrd	GarageCars	YrSold	SalePrice
0	1146	6	2	2007	187500
1	2622	9	2	2010	325000
2	1440	8	0	2008	118000
3	1040	5	1	2010	133000
4	936	4	2	2009	93000
..	…	…	…	…	…
895	1716	7	2	2009	191000
896	924	6	2	2007	122900
897	2353	10	2	2009	260000

```
898       2169             7           2    2007      228500
899       1536             7           2    2008      214000

[898 rows x 17 columns]
```

[44]:
```
rawdata = dataP.loc[:,"MSZoning":"GarageCars"]
rawdata
```

[44]:
```
     MSZoning  LotArea  Neighborhood  BldgType  OverallQual  OverallCond  \
332         1    10998             4         1            5            5
639         1    12378             9         1            9            5
327         1     6600            13         1            5            9
850         1     7052             9         2            7            5
39          1    12456             9         1           10            5
..        …       …             …         …           …            …
107         2     4608             3         1            4            6
271         1     8400            17         1            5            8
862         1    11988            11         1            6            7
436         1     8400             2         1            7            5
103         1     8400            17         1            2            5

     YearBuilt  YearRemodAdd  RoofStyle  TotalBsmtSF  HeatingQC  CentralAir  \
332       1941          1960          1          984          1           1
639       2003          2004          1         1896          1           1
327       1982          2008          1          816          1           1
850       2005          2005          1         1364          1           1
39        2006          2007          2         1700          1           1
..         …             …         …           …         …           …
107       1945          1950          1          747          2           1
271       1939          1997          1          720          1           1
862       1934          1995          2          715          4           1
436       2004          2005          1         1473          1           1
103       1920          1950          1          290          2           2

     GrLivArea  GarageCars
332       1604           2
639       1944           3
327        816           1
850       1364           2
39        1718           3
..         …           …
107        747           1
271       2192           1
862       1660           1
436       1484           2
103        438           1
```

```
[898 rows x 14 columns]
```

Year Sold wird rausgenommen, da fast keine Korrelation zu dem Rest

[45]:
```
trainData = rawdata[0:math.floor(lenDataSet*0.8)]
```

[46]:
```
validateData = rawdata[math.ceil(lenDataSet*0.8):math.floor(lenDataSet*0.95)]
```

[47]:
```
testData = rawdata[math.ceil(lenDataSet*0.95):]
```

[48]:
```
trainLabels = labels[0:math.floor(lenDataSet*0.8)]
```

[49]:
```
validateLabels = labels[math.ceil(lenDataSet*0.8):math.floor(lenDataSet*0.95)]
```

[50]:
```
testLabels = labels[math.ceil(lenDataSet*0.95):]
```

Es ist bewusst das es auch vorgefertigte Methoden zum splitten gibt. Es wurde sich für diese Methode enschieden, weil diese für uns einfacher zu lesen war

3 Aufgabenteil 2 - Vorhersage SalePrice

3.1 Random Forest Regressor

[51]:
```
rfR = RandomForestRegressor(n_estimators = 1000, random_state = 42,␣
↪max_features = 3)
rfR.fit(trainData, trainLabels)
#n_estimators = Anzahl an trees
#random_state = Seed um immer gleiches Ergebnis zu bekommen
#max_featurs = anzahl der feautres maximal
```

[51]:
```
RandomForestRegressor(bootstrap=True, criterion='mse', max_depth=None,
                      max_features=3, max_leaf_nodes=None,
                      min_impurity_decrease=0.0, min_impurity_split=None,
                      min_samples_leaf=1, min_samples_split=2,
                      min_weight_fraction_leaf=0.0, n_estimators=1000,
                      n_jobs=None, oob_score=False, random_state=42, verbose=0,
                      warm_start=False)
```

[52]:
```
rfR.score(validateData, validateLabels)
#score um Überblick zu bekommen
```

[52]:
```
0.9174617531675052
```

[53]:
```
rfK = RandomForestRegressor(n_estimators = 1000, random_state = 42,␣
↪max_features = 3)
scores = cross_val_score(rfK, trainData, trainLabels, cv=5)
scores
```

[53]:
```
array([0.88123051, 0.83794313, 0.90861283, 0.89474147, 0.82423702])
```

[54]:
```
rfK = RandomForestRegressor(n_estimators = 1000, random_state = 42,␣
 ↪max_features = "sqrt")
scores = cross_val_score(rfK, trainData, trainLabels, cv=5)
scores
```

[54]:
```
array([0.88123051, 0.83794313, 0.90861283, 0.89474147, 0.82423702])
```

3.2 Gradient Boosting Regressor

[55]:
```
gbR = GradientBoostingRegressor(
    max_depth=1,
    n_estimators=1000,
    learning_rate=0.1
)
gbR.fit(trainData, trainLabels)
gbR.score(validateData, validateLabels)
#gbr.predict(rawdata[1:2])
```

[55]:
```
0.9151610106239003
```

3.3 Lineare Regression

[56]:
```
linearData = trainData.iloc[:, [4 ,9, 12]]
#Data Preparation für Lineare Regression
```

[57]:
```
clf = LinearRegression().fit(linearData, trainLabels)
#clf.coef_
#clf.intercept_
#clf.score
```

[58]:
```
linearDataV = validateData.iloc[:, [4 ,9, 12]]
clf.score(linearDataV,validateLabels)
```

[58]:
```
0.8522736694312071
```

[59]:
```
clf.coef_
```

[59]:
```
array([21778.7995944 ,    47.55354281,    59.93549851])
```

[60]:
```
clf.intercept_
```

[60]:
```
-93010.30612691233
```

[61]:
```
data[1:4]
```

[61]:
```
   MSZoning  LotArea Neighborhood BldgType  OverallQual  OverallCond  \
1        RL    12256      NoRidge     1Fam            8            5
2        RL    12108      Edwards   Duplex            4            4
3        RL     7500       Sawyer     1Fam            5            5

   YearBuilt  YearRemodAdd RoofStyle  TotalBsmtSF HeatingQC CentralAir  \
1       1994          1995     Gable         1463        Ex          Y
2       1955          1955     Gable         1440        TA          N
3       1963          1963     Gable         1040        Fa          Y

   GrLivArea  TotRmsAbvGrd  GarageCars  YrSold  SalePrice
1       2622             9           2    2010     325000
2       1440             8           0    2008     118000
3       1040             5           1    2010     133000
```

3.4 Berechnung des Sales Prices von Hand

Die Werte in den Spalten der Daten werden mit den Koeffectienten multipliziert und dann wird zum Schluss der Intercept als Kosntante hinzugerechnet.

Datensatz 1: SalePrice = 45.01412324 * OverallQual + 45.01412324 * TotalBsmtSF + 59.93549851 * GrLIvArea -93010.30612691233 SalePrice = 21778.7995944 * 8 + 45.01412324 * 1463 + 59.93549851 * 2622 - 93010.30612691233 (1) predicted SalePrice = 307941.8008510381 actuelle SalePrice = 325000 p(Abweichung) = 1 -307941.8008510381/325000 = 0.05248676661219054

Datensatz 2: SalePrice = 21778.7995944 * 4 + 45.01412324 * 1440 + 59.93549851 * 1440 - 93010.30612691233 (2) predicted SalePrice = 148889.11174950577 actuelle SalePrice = 118000 p(Abweichung) = 118000/148889.11174950577 = 0.261772133470388

Datensatz 3: SalePrice = 21778.7995944 * 5 + 45.01412324 * 1040 + 59.93549851 * 1040 - 93010.30612691233 (3) predicted SalePrice = 127672.29481644908 actuelle SalePrice = 133000 p(Abweichung) = 1 -127672.29481644908/133000 = 0.040057933710909155

[62]:
```
clf.predict(data.iloc[1:2, [4 ,9, 12]])
```

[62]:
```
array([307941.80085104])
```

[63]:
```
clf.predict(data.iloc[2:3, [4 ,9, 12]])
```

[63]:
```
array([148889.11174951])
```

[64]:
```
clf.predict(data.iloc[3:4, [4 ,9, 12]])
```

[64]:
```
array([127672.29481645])
```

Für die Auswahl und Optimierung der Modelle siehe weiter unten.

4 Aufgabenteil 3 - Vorhersage ob es eine Klimananlage gibt (Central Air)

4.1 Kurze Preparation

[65]:
```
caData = dataP.loc[:, dataP.columns != 'CentralAir']
caData
```

[65]:

	MSZoning	LotArea	Neighborhood	BldgType	OverallQual	OverallCond
332	1	10998	4	1	5	5
639	1	12378	9	1	9	5
327	1	6600	13	1	5	9
850	1	7052	9	2	7	5
39	1	12456	9	1	10	5
..	…	…	…	…	…	…
107	2	4608	3	1	4	6
271	1	8400	17	1	5	8
862	1	11988	11	1	6	7
436	1	8400	2	1	7	5
103	1	8400	17	1	2	5

	YearBuilt	YearRemodAdd	RoofStyle	TotalBsmtSF	HeatingQC	GrLivArea
332	1941	1960	1	984	1	1604
639	2003	2004	1	1896	1	1944
327	1982	2008	1	816	1	816
850	2005	2005	1	1364	1	1364
39	2006	2007	2	1700	1	1718
..	…	…	…	…	…	…
107	1945	1950	1	747	2	747
271	1939	1997	1	720	1	2192
862	1934	1995	2	715	4	1660
436	2004	2005	1	1473	1	1484
103	1920	1950	1	290	2	438

	GarageCars	SalePrice
332	2	117000
639	3	360000
327	1	130500
850	2	185850
39	3	337500
..	…	…
107	1	80000
271	1	179500
862	1	188700
436	2	213000
103	1	60000

```
[898 rows x 14 columns]
```

[66]:
```
caLabels = dataP["CentralAir"]
caLabels
```

[66]:
```
332    1
639    1
327    1
850    1
39     1
      ..
107    1
271    1
862    1
436    1
103    2
Name: CentralAir, Length: 898, dtype: int64
```

[67]:
```
trainCaData = caData[0:math.floor(lenDataSet*0.8)]
```

[68]:
```
validateCaData = caData[math.ceil(lenDataSet*0.8):math.floor(lenDataSet*0.95)]
```

[69]:
```
testCaData = caData[math.ceil(lenDataSet*0.95):]
```

[70]:
```
trainCaLabels = caLabels[0:math.floor(lenDataSet*0.8)]
```

[71]:
```
validateCaLabels = caLabels[math.ceil(lenDataSet*0.8):math.floor(lenDataSet*0.
↪95)]
```

[72]:
```
testCaLabels = caLabels[math.ceil(lenDataSet*0.95):]
```

4.2 Decision Tree Classifier

[73]:
```
dtC= tree.DecisionTreeClassifier()
dtC = dtC.fit(trainCaData, trainCaLabels)
dtC.score(validateCaData,validateCaLabels)
#Verwendung Score für einen kurzen Eindruck
```

[73]:
```
0.9402985074626866
```

4.3 Random Forest Classifier

[74]:
```
rfC = RandomForestClassifier(max_depth=2, random_state=0)
rfC.fit(trainCaData, trainCaLabels)
rfC.score(validateCaData, validateCaLabels)
```

```
C:\Users\meton\Anaconda3\lib\site-packages\sklearn\ensemble\forest.py:245:
FutureWarning: The default value of n_estimators will change from 10 in version
0.20 to 100 in 0.22.
  "10 in version 0.20 to 100 in 0.22.", FutureWarning)
```

[74]:
```
0.9328358208955224
```

4.4 Gradient Boosting Classifier

[75]:
```
gbC = GradientBoostingClassifier(n_estimators=20, max_features=2, max_depth=2,␣
 ↪random_state=0)
gbC.fit(trainCaData, trainCaLabels)
gbC.score(validateCaData, validateCaLabels)
```

[75]:
```
0.9402985074626866
```

93% der Häuser haben eine Klimaanlage. Beachten!!!

5 Auswahl und Optimierung der Modelle

5.1 Regression

5.1.1 Preparation

[76]:
```
rg = []
testdata = data[math.ceil(lenDataSet*0.8):]
```

Testdaten wurden um Validation Daten erweitert, weil Testdaten sonst zu klein waren und iwr das Gefühl hatten keine gute Aussage treffen zu können. Zum Beispiel bei der Classification hatten alle Testdaten eine Klimaanlage.

5.1.2 Auswahl Modells

[77]:
```
#Linear Regression
rg.append(applyRegressor(clf,testdata))
```

[78]:
```
#Gradient Boosting Tree Regression
rg.append(applyRegressor(gbR,testdata))
```

[79]:
```
#Random Forest Regression
rg.append(applyRegressor(rfR,testdata))
```

[80]:
```
r2=[]
mse=[]
rmse = []
mape=[]
maxD=[]
for i in rg:
```

```
    #Ergebnisse der Modelle einfügen
    r2.append(i["r2"])
    mse.append(i["mse"])
    rmse.append(i["rmse"])
    mape.append(i["mape"])
    maxD.append(i["maxDiff"])
```

Auswertung der Ergebnisse

[81]:
```
sb.barplot(["Linear","Gradient Boosting Tree","Random Forest"],r2)
```

[81]:
```
<matplotlib.axes._subplots.AxesSubplot at 0x17a93d4b348>
```

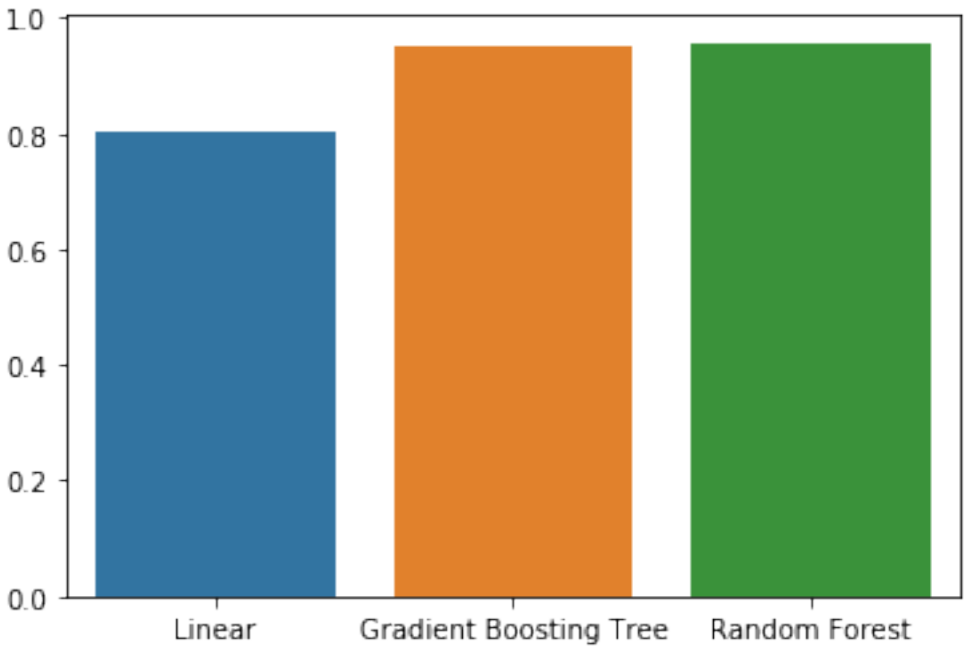

[82]:
```
sb.barplot(["Linear","Gradient Boosting Tree","Random Forest"],mse)
```

[82]:
```
<matplotlib.axes._subplots.AxesSubplot at 0x17a93d51d48>
```

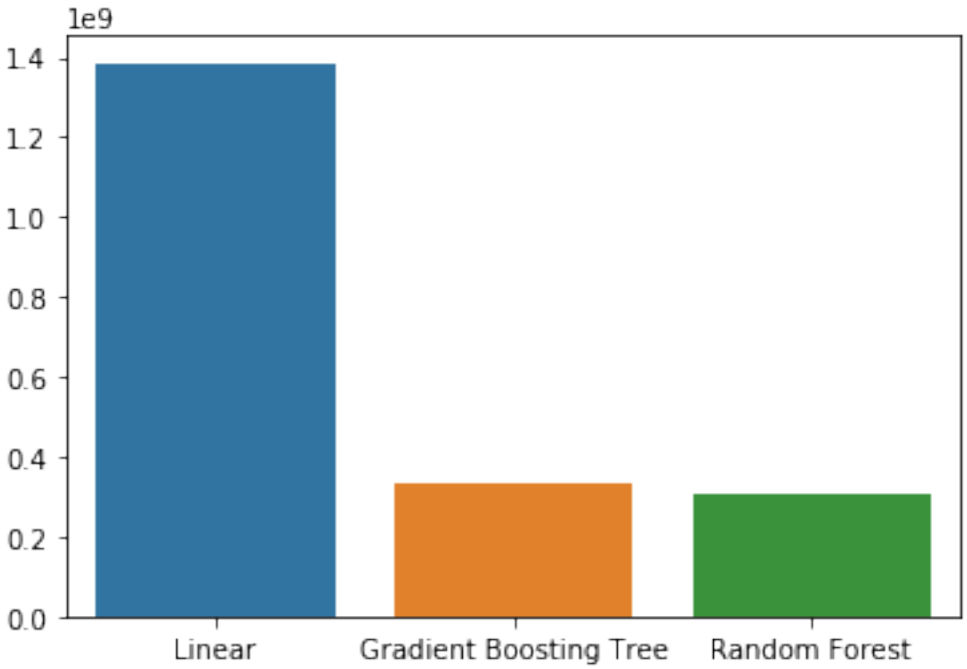

[83]:
```
sb.barplot(["Linear","Gradient Boosting Tree","Random Forest"],rmse)
```

[83]: <matplotlib.axes._subplots.AxesSubplot at 0x17a99f909c8>

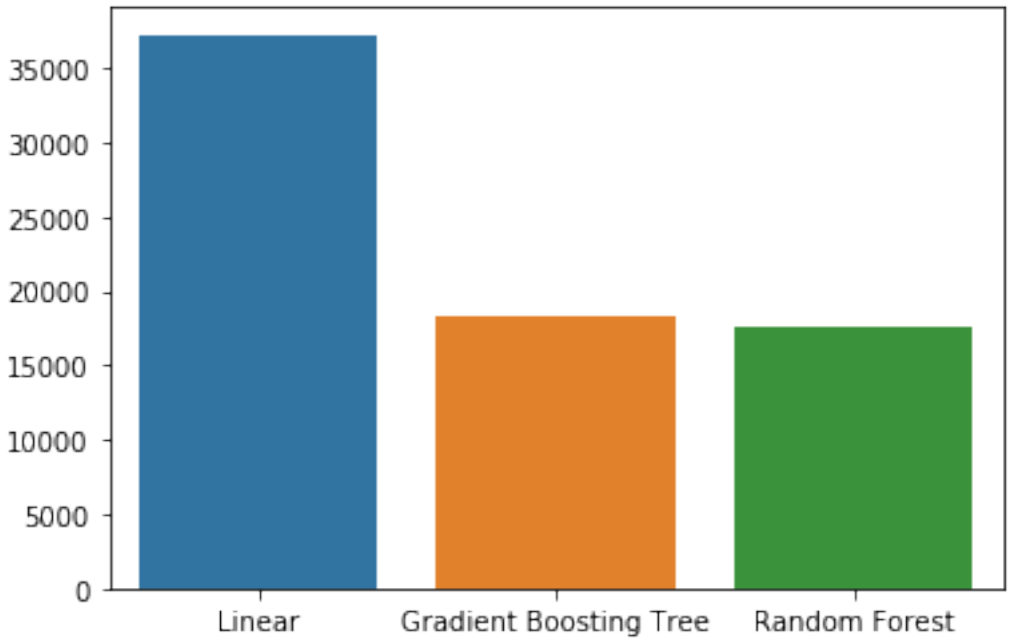

[84]:
```
sb.barplot(["Linear","Gradient Boosting Tree","Random Forest"],mape)
```

[84]: <matplotlib.axes._subplots.AxesSubplot at 0x17a95e4fd88>

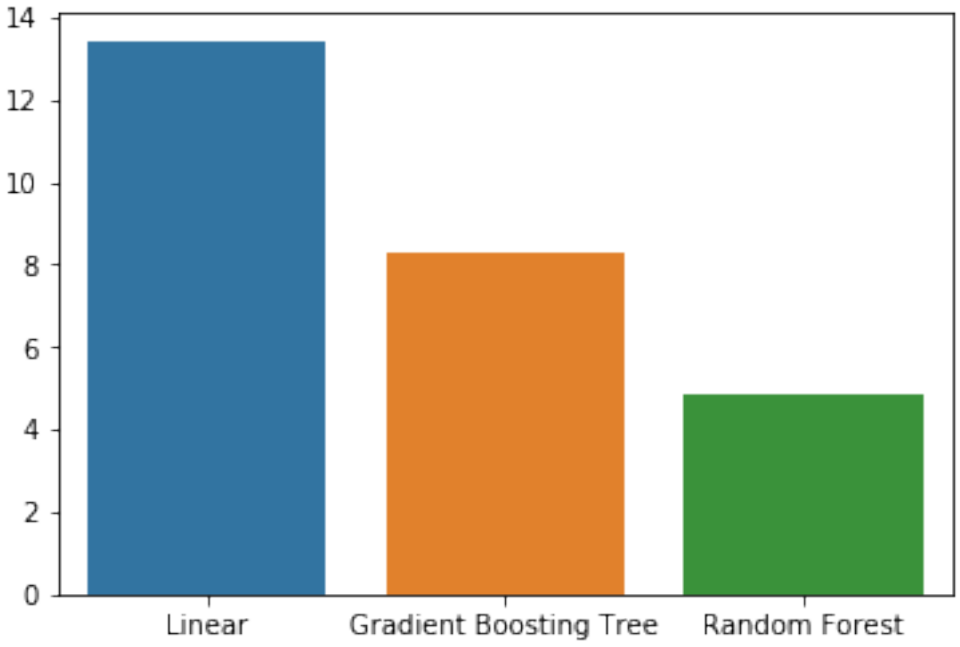

[85]:
```
sb.barplot(["Linear","Gradient Boosting Tree","Random Forest"],maxD)
```

[85]: <matplotlib.axes._subplots.AxesSubplot at 0x17a96eaaa08>

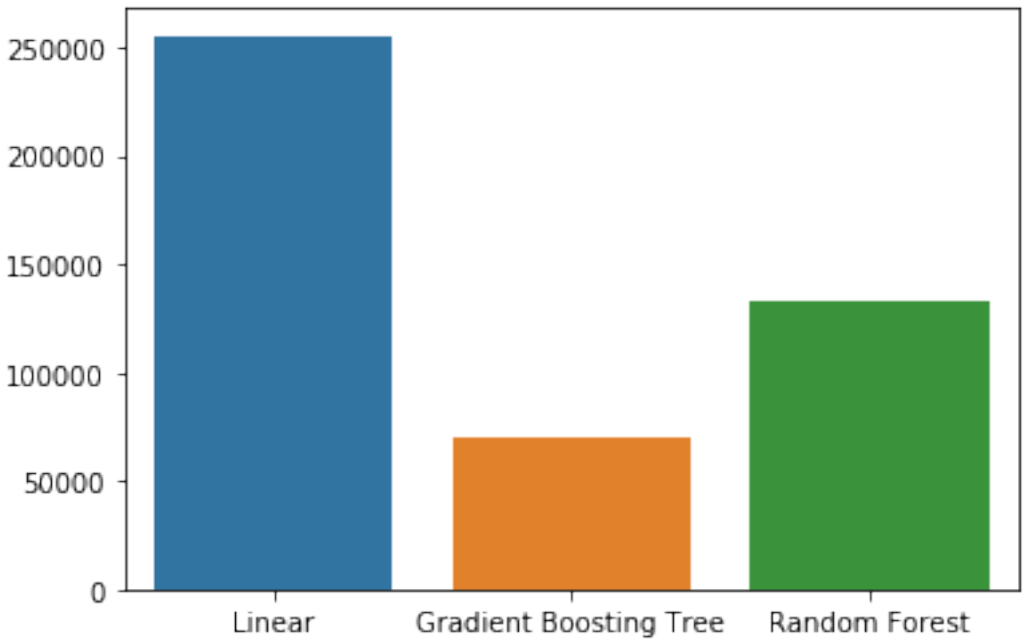

Wie erwartet ist der Lineare Regressor der mit Abstand schlechteste Regressor unserer Modelle, da es sich nur auf 3 Werte aus den gegebenen Werten bezieht und es vom Aufbau mit das leichteste ist.

Gradient Boosting Tree Regressor und Random Forest Regressor unterscheiden sich in den Messwerten R^2, MSE und RMSE relativ wenig. Sie unterscheiden sich in der maximalen Differenz und dem MAPE Wert. Wir bevorzugen den MAPE Wert, weil die Maximale Differenz wenig aussagt, da sie durch einen Ausreißer stark verändert werden kann. Da aber Random Forest einen besseren MAPE Wert besitzt werden wir dieses Modell weiter optimieren.

5.2 Classification

Preparation von der Regression wird verwendet (aka Daten splitten)

5.2.1 Auswahl Modells

[86]:
```
cl = []
```

[87]:
```
#Decision Tree Classifier
cl.append(applyClassifier(dtC, testdata))
```

[88]:
```
#Random Forest Classifier
cl.append(applyClassifier(rfC, testdata))
```

[89]:
```
#Gradient Boosting Tree Classifier
cl.append(applyClassifier(gbC, testdata))
```

[90]:
```
#{"accuracy": accuracy, "falsePositiveRate": falsePositiveRate,␣
 ↪"falseNegativeRate": falseNegativeRate}
accuracy= []
falsePositiveRate =[]
falseNegativeRate = []

for i in cl:
    #Ergebnisse der Modelle einfügen
    print(i)
    #Print um unterschiede in den Zahlenwerten zu erkennen
    accuracy.append(i["accuracy"])
    falsePositiveRate.append(i["falsePositiveRate"])
    falseNegativeRate.append(i["falseNegativeRate"])
```

```
{'accuracy': 0.994413407821229, 'falsePositiveRate': 0.125, 'falseNegativeRate':
0.0}
{'accuracy': 0.9553072625698324, 'falsePositiveRate': 1.0, 'falseNegativeRate':
0.0}
```

```
{'accuracy': 0.9664804469273743, 'falsePositiveRate': 0.75, 'falseNegativeRate':
0.0}
```

Auswertung der Ergebnisse

[91]:
```
sb.barplot(["Tree","Random Forest","Gradient Boosting Tree"],accuracy)
```

[91]:
```
<matplotlib.axes._subplots.AxesSubplot at 0x17a98f02b88>
```

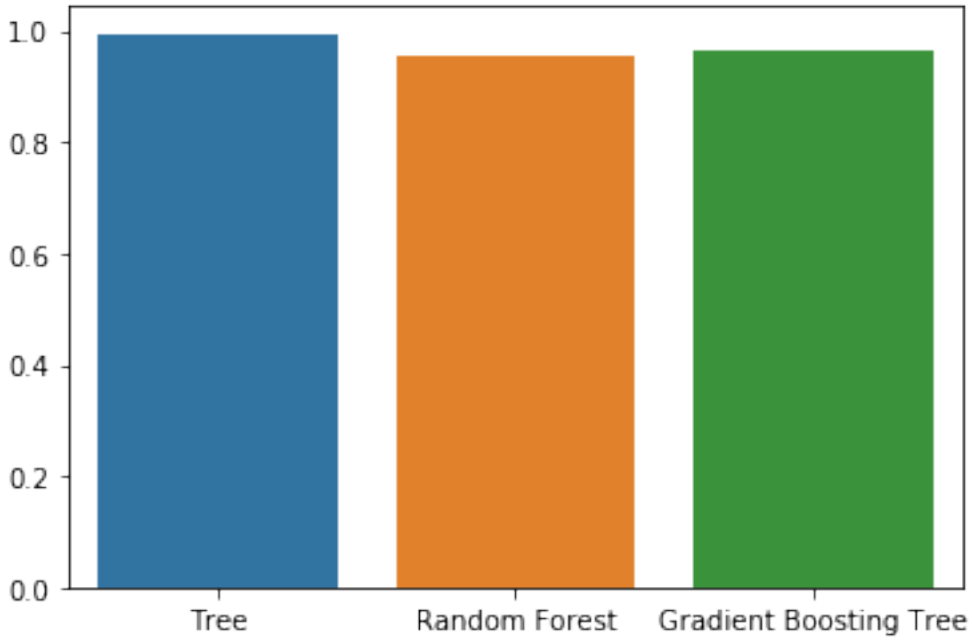

[92]:
```
sb.barplot(["Tree","Random Forest","Gradient Boosting Tree"],falsePositiveRate)
```

[92]:
```
<matplotlib.axes._subplots.AxesSubplot at 0x17a99f2c308>
```

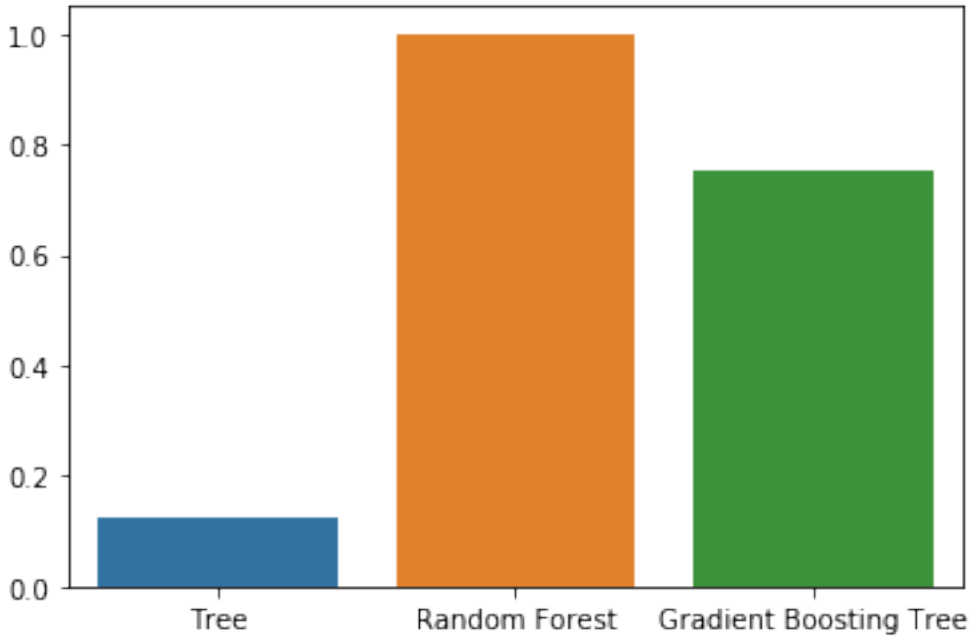

[93]:
```
sb.barplot(["Tree","Random Forest","Gradient Boosting Tree"],falseNegativeRate)
```

[93]: <matplotlib.axes._subplots.AxesSubplot at 0x17a9c1a5208>

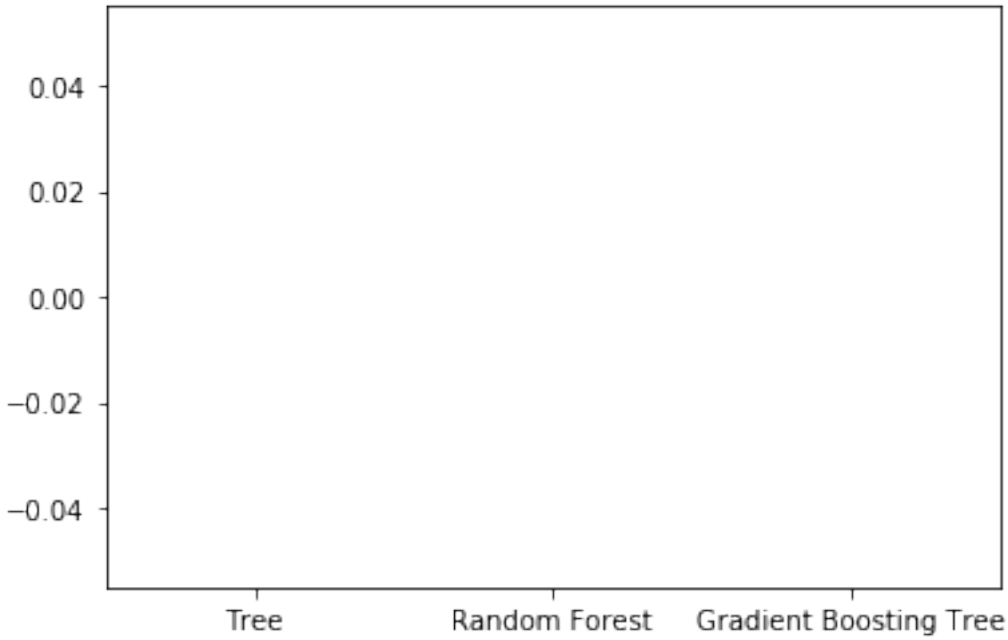

Der Entscheidungsbaum hat wie man sieht die höchste Accuracy und eine gegenüber den anderen

Modellen kleinere false Positive Rate.

Was auffällt: Bei allen Classifieren liegt die false Negative Rate überall bei 0.

Aufgrund der höheren Accuracy und den allgemein besseren Werten entscheiden wir uns dafür den Entscheidungsbaum zu optimieren und später einzusetzen. Auch wenn der Entscheidungsbaum normalerweise zu den schlechteren Modellen gehört.

6 Optimierung der Modelle

6.1 Optimierung Random Forest Regressor

[94]:
```
#Alt:
applyRegressor(rfR,testdata)
```

[94]:
```
{'r2': 0.9560993529271428,
 'mse': 307851582.9420675,
 'rmse': 17545.699841900507,
 'mape': 4.865994812443826,
 'maxDiff': 132639.17599999998}
```

[95]:
```
rfR2 = RandomForestRegressor(n_estimators = 100000, random_state = 42,␣
 ↪max_features = 3)
rfR2.fit(trainData, trainLabels)
applyRegressor(rfR2,testdata)
```

[95]:
```
{'r2': 0.9596224600638193,
 'mse': 283145930.94790906,
 'rmse': 16826.94062947597,
 'mape': 4.842240202001849,
 'maxDiff': 124262.47597000003}
```

Eine höhere Anzahl an Estimators bringt eine höhere Performance in den Messwerten, doch das Berechnen wird immer langsamer sodass wir den Wert für die Tests nicht weiter erhöhen werden als 10000. Die Performance der Messwerte scheint sich einem Grenzwert anzunähern.

[96]:
```
rfR3 = RandomForestRegressor(n_estimators = 10000, random_state = 42,␣
 ↪max_features = 3)
rfR3.fit(trainData, trainLabels)
applyRegressor(rfR3,testdata)
```

[96]:
```
{'r2': 0.9596921006232065,
 'mse': 282657579.22933996,
 'rmse': 16812.42335980569,
 'mape': 4.860086231216309,
 'maxDiff': 122596.54929999996}
```

[97]:
```
rfR3 = RandomForestRegressor(n_estimators = 10000, random_state = 42,␣
↪max_features = 4)
rfR3.fit(trainData, trainLabels)
applyRegressor(rfR3,testdata)
```

[97]:
```
{'r2': 0.9638271582018716,
 'mse': 253660648.5226929,
 'rmse': 15926.727489434008,
 'mape': 4.782334863470758,
 'maxDiff': 110640.13919999998}
```

[98]:
```
rfR4 = RandomForestRegressor(n_estimators = 10000, random_state = 42,␣
↪max_features = 10)
rfR4.fit(trainData, trainLabels)
applyRegressor(rfR4,testdata)
```

[98]:
```
{'r2': 0.9668657449184039,
 'mse': 232352677.1609313,
 'rmse': 15243.119010259392,
 'mape': 4.876909028725267,
 'maxDiff': 91858.71299999999}
```

[99]:
```
rfR5 = RandomForestRegressor(n_estimators = 10000, random_state = 42,␣
↪max_features = 7)
rfR5.fit(trainData, trainLabels)
applyRegressor(rfR5,testdata)
```

[99]:
```
{'r2': 0.9666794652310243,
 'mse': 233658956.23546538,
 'rmse': 15285.907111959872,
 'mape': 4.779284998759749,
 'maxDiff': 97630.89820000005}
```

[100]:
```
rfR6 = RandomForestRegressor(n_estimators = 10000, random_state = 42,␣
↪max_features = 6)
rfR6.fit(trainData, trainLabels)
applyRegressor(rfR6,testdata)
```

[100]:
```
{'r2': 0.9662487872371085,
 'mse': 236679068.94463012,
 'rmse': 15384.37743116796,
 'mape': 4.760277303939834,
 'maxDiff': 100803.7352}
```

[101]:
```
rfR7 = RandomForestRegressor(n_estimators = 10000, random_state = 42,␣
↪max_features = 8)
rfR7.fit(trainData, trainLabels)
```

```
applyRegressor(rfR7,testdata)
```

[101]:
```
{'r2': 0.9666710114435733,
 'mse': 233718238.0917064,
 'rmse': 15287.84609065994,
 'mape': 4.835020220092167,
 'maxDiff': 96630.35360000003}
```

Wir entscheiden uns für einen Baum mit 6 Features, da er einen niedrigen MAPE Wert aufweißt und die anderen Faktoren, dadurch nicht so viel in Mitleidenschaft gezoigen werden, wie bei anderen Random Forests.

[102]:
```
rfRFinal = RandomForestRegressor(n_estimators = 10000, random_state = 42,␣
↪max_features = 6)
rfRFinal.fit(trainData, trainLabels)
applyRegressor(rfRFinal,testdata)
```

[102]:
```
{'r2': 0.9662487872371085,
 'mse': 236679068.94463012,
 'rmse': 15384.37743116796,
 'mape': 4.760277303939834,
 'maxDiff': 100803.7352}
```

6.2 Optimieren des Decision Treee Classifiers

[103]:
```
dtC = tree.DecisionTreeClassifier(criterion="gini", max_depth = None,␣
↪min_samples_split = 2)
dtC = dtC.fit(trainCaData, trainCaLabels)
applyClassifier(dtC, testdata)
```

[103]:
```
{'accuracy': 0.994413407821229,
 'falsePositiveRate': 0.125,
 'falseNegativeRate': 0.0}
```

[104]:
```
dtC2 = tree.DecisionTreeClassifier(criterion="entropy", max_depth = None,␣
↪min_samples_split = 2)
dtC2.fit(trainCaData, trainCaLabels)
applyClassifier(dtC2, testdata)
```

[104]:
```
{'accuracy': 0.994413407821229,
 'falsePositiveRate': 0.125,
 'falseNegativeRate': 0.0}
```

[105]:
```
dtC3 = tree.DecisionTreeClassifier(criterion="entropy", max_depth = 11,␣
↪min_samples_split = 2)
dtC3.fit(trainCaData, trainCaLabels)
applyClassifier(dtC3, testdata)
```

[105]:
```
{'accuracy': 0.9888268156424581,
 'falsePositiveRate': 0.125,
 'falseNegativeRate': 0.0058479533}
```

[106]:
```
dtC4 = tree.DecisionTreeClassifier(criterion="gini", max_depth = 4,␣
 ↪min_samples_split = 2)
dtC4.fit(trainCaData, trainCaLabels)
applyClassifier(dtC4, testdata)
```

[106]:
```
{'accuracy': 0.994413407821229,
 'falsePositiveRate': 0.125,
 'falseNegativeRate': 0.0}
```

Sobald man das Kriterium ändert und ein bisschen mit der Max Tiefe rumspielt, erhält man das Ergebnis, dass das Kriterium Gini anscheinend besser ist als Entropy, da es mit einer geringeren Tiefe von 4 (bei Gini) zu 11 (bie Entropy) die gelcihe Accuracy und Rates bringt.

[107]:
```
dtC5 = tree.DecisionTreeClassifier(criterion="gini", max_depth = 4,␣
 ↪min_samples_split = 26)
dtC5.fit(trainCaData, trainCaLabels)
applyClassifier(dtC5, testdata)
```

[107]:
```
{'accuracy': 0.9664804469273743,
 'falsePositiveRate': 0.375,
 'falseNegativeRate': 0.01754386}
```

Die Variation von minimalen Samples bringt keine besseren Ergebnisse als wir nciht sowieso schon haben. Auch andere Variationen brachten keine weiteren Ergebnisse. Draraus folgend werden wir die Voreinstellungen mit Kriterium gleich Gini, einer unbegrenzten mmaximalen Tiefe und Splitten bei 2, verwenden.

Uns kommt das Ergebnis von einer Accuarcy von 0,99…. eher komisch vor aber wir finden keine Erklärung, deswegen arbeiten wir trotzdem damit weiter. Grund dafür könnten laut unserer Überlegungen das Testen auf Trainingsdaten oder das Trainieren auf Testdaten sein. Beides trifft nciht zu. Eine andere Möglichkeit wär das Trainieren und Testen mit den Labels drinnen, was aber auch nciht zutrifft.

[108]:
```
dtCFinal = tree.DecisionTreeClassifier(criterion="gini", max_depth = None,␣
 ↪min_samples_split = 2)
dtCFinal.fit(trainCaData, trainCaLabels)
applyClassifier(dtCFinal, testdata)
```

[108]:
```
{'accuracy': 0.994413407821229,
 'falsePositiveRate': 0.125,
 'falseNegativeRate': 0.0}
```

[109]:
```
exportModels("trainedModels.joblib", rfRFinal, dtCFinal)
```

7 Anwenden der Modelle auf Trainingsdatensatz, Testdatensatz und den gesammten Datensatz

Anmerkung: Die Daten sind die gleichen wie oben verwendet da Reihenfolge immer gleich bleibt. Werden nur hier, wel sie vorher in Data und Labels getrennt wurden neu in Zeilen aufgeteilt.

[110]:
```
trainData = data[0:math.floor(lenDataSet*0.8)]
```

Validation Data wird nicht benötigt.

[111]:
```
testData = data[math.ceil(lenDataSet*0.95):]
```

7.1 Regression

[112]:
```
applyRegressor(rfRFinal, trainData)
```

[112]:
```
{'r2': 0.970958383614906,
 'mse': 133094331.79078487,
 'rmse': 11536.651671554657,
 'mape': 4.679743733780902,
 'maxDiff': 65112.36680000002}
```

[113]:
```
applyRegressor(rfRFinal, testData)
```

[113]:
```
{'r2': 0.9622804723307457,
 'mse': 407933384.27035356,
 'rmse': 20197.360824383803,
 'mape': 4.727154104556354,
 'maxDiff': 100866.26839999994}
```

[114]:
```
applyRegressor(rfRFinal, data)
```

[114]:
```
{'r2': 0.9737959749253781,
 'mse': 133160792.83489668,
 'rmse': 11539.53174244504,
 'mape': 4.439607474060039,
 'maxDiff': 86444.59270000004}
```

7.2 Classification

[115]:
```
applyClassifier(dtCFinal, trainData)
```

[115]:
```
{'accuracy': 0.9888579387186629,
 'falsePositiveRate': 0.10869565,
 'falseNegativeRate': 0.004464286}
```

[116]:
```
applyClassifier(dtCFinal, testData)
```

[116]:
```
{'accuracy': 1.0, 'falsePositiveRate': 0, 'falseNegativeRate': 0.0}
```

[117]:
```
applyClassifier(dtCFinal, data)
```

[117]:
```
{'accuracy': 0.9899777282850779,
 'falsePositiveRate': 0.11111111,
 'falseNegativeRate': 0.0035545023}
```

8 Visualisierung Decision Tree

[118]:
```
plt.figure(figsize=(200,200))
abc = tree.plot_tree(dtCFinal,feature_names = trainCaData.columns, filled =␣
↪True, node_ids = False, fontsize = 100)
```

[119]:
```
testCaData[1:3]
```

[119]:

	MSZoning	LotArea	Neighborhood	BldgType	OverallQual	OverallCond	\
476	2	6240	8	1	5	4	
682	1	9572	14	1	8	5	

	YearBuilt	YearRemodAdd	RoofStyle	TotalBsmtSF	HeatingQC	GrLivArea	\
476	1936	1950	1	896	3	1344	
682	1990	1990	1	1453	1	2810	

	GarageCars	SalePrice
476	1	115000
682	2	302000

Links yes; Rechts no

Es wird jeweils der Wert des Datensatzes an der Stelle vergleichen und wenn der Vergleich ja ist wird nach links gegangen und galls es nicht zutrifft nach rechts auf dem Baum gegangen.

Durchführen des Decision Trees auf Datensatz 476: SalePrice: Ist 115000 <= 98150? no -> rechts MSZoning: Ist 2 <= 3.5? ja -> links YearBuild: Ist 1936 <= 1913? nein -> rechts BldgType: Ist 1 <= 4.5? ja -> links GarageCars: Ist 1 <= 0.5? nein -> rechts YearBuilt: Ist 1936 <= 1918.5? nein -> rechts OverallCondition: Ist 4 <= 3.5? nein -> rechts YearBuilt: Ist 1936 <= 1954? nein -> rechts Ergebnis: Die Wohnung hat ein Central Air, da in den Values nur positive Wertte vorkommen.

Durchführen des Decision Trees auf Datensatz 682: SalePrice: Ist 302000 <= 98150? no -> rechts MSZoning: Ist 1 <= 3.5? ja -> links YearBuild: Ist 1990 <= 1913? nein -> rechts BldgType: Ist 1 <= 4.5? ja -> links GarageCars: Ist 2 <= 0.5? nein -> rechts YearBuilt: Ist 1990 <= 1918.5? nein -> rechts OverallCondition: Ist 5 <= 3.5? nein -> rechts YearBuilt: Ist 1990 <= 1954? nein -> rechts Ergebnis: Die Wohnung hat ein Central Air, da in den Values nur positive Wertte vorkommen.

Für beide Wohnungen ist der Ablauf aus Zufall gleich. Treotzdem sollte der Ablauf gut dargestellt sein.

[120]:
```
testCaLabels[1:3]
```

[120]:
```
476    1
682    1
Name: CentralAir, dtype: int64
```